

# 基于深度学习的无线信号认知技术研究

作者姓名 赵纪伟

指导教师姓名、职称 杨清海 教授

申请学位类别 工学硕士



学校代码 10701  
分类号 TP391

学号 1501120264  
密级 公开

# 西安电子科技大学

## 硕士学位论文

### 基于深度学习的无线信号认知技术研究

作者姓名：赵纪伟

一级学科：信息与通信工程

二级学科：通信与信息系统

学位类别：工学硕士

指导教师姓名、职称：杨清海 教授

学 院：通信工程学院

提交日期：2018 年 4 月



**Thesis/Dissertation LaTeX Template for  
Postgraduates  
of XIDIAN UNIVERSITY**

A Thesis submitted to  
XIDIAN UNIVERSITY  
in partial fulfillment of the requirements  
for the degree of Master

By  
Jackokie Zhao  
Supervisor: Qinghai Yang Title: Professor  
April 2018



## 西安电子科技大学 学位论文独创性（或创新性）声明

秉承学校严谨的学风和优良的科学道德，本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同事对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。学位论文若有不实之处，本人承担一切法律责任。

本人签名：\_\_\_\_\_

日 期：\_\_\_\_\_

## 西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权属于西安电子科技大学。学校有权保留送交论文的复印件，允许查阅、借阅论文；学校可以公布论文的全部或部分内容，允许采用影印、缩印或其它复制手段保存论文。同时本人保证，结合学位论文研究成果完成的论文、发明专利等成果，署名为西安电子科技大学。  
保密的学位论文在\_\_\_\_\_年解密后适用本授权书。

本人签名：\_\_\_\_\_

导师签名：\_\_\_\_\_

日 期：\_\_\_\_\_

日 期：\_\_\_\_\_





## 调制识别的深度框架研究

### 0.1 引言

尽管机器学习的目的是提供一种通用的问题解决算法，但目前性能最优的网络模型大部分仍然是对应于特定应用的。目前存在几种较完善的网络，比如包括多层感知机、RNN、CNN 及其许多变体以等，他们被应用在各个领域，取得了很好效果。然而，由于模型所面对的环境不同，数据不同，数据分布也不同；因此，其他领域的很多模型对于我们的调制识别任务并不一定完全适应，需要进行相应的探索。

在第三章中，我们基于网络模型的层面，提出了一种不同类型深度模型融合的深度网络框架，并将其应用到无线信号调制识别任务中，而且取得了一定的性能提升。在本章中，我们将以 LeCun 的经典五层网络结构为基准，从网络底层研究网络超参数对调制识别性能的影响，并从欠拟合与过拟合的角度来理解出现这些现象的原因。

### 0.2 系统模型

在大部分现有的深度神经网络中，卷积层是它们共有的基本网络单元。每个卷积层由若干个卷积核组成，每个卷积核通常非常小（1x1 到 5x5 是图像处理中的常见尺寸）。在传统的 DSP 应用中，卷积核通常设计得非常宽，而非设计成很深的多层结构。计算机视觉领域中，神经网络的一个明显趋势是建立更深的网络来学习更复杂的函数变换和层次特征关系。

标准卷积层  $\mathbf{I}$  的传递函数在方程0-1中给出：

$$f(I_i) = f(b_j + \sum_i (k_{ij} * I_i)) \quad (0-1)$$

其中， $f(I_i)$  是第  $i$  个卷积核的输出特征图（Feature Map）， $b$  和  $k$  表示卷积核的偏置和卷积核的权重参数， $I_i$  代表卷积核的输入值， $*$  表示卷积运算，并且  $f(\cdot)$  表示诸如整流线性单元（ReLU）或 Sigmoid 单元等激活函数。

本章中，我们所有的网络结构都是基于图1的框架，基准的卷积神经网络在 Softmax 分类层之前有两个卷积层和一个全连接层，Softmax 层之后输出样本分类结果。

整个网络中，我们所变化的只是网络的层数、卷积核的高度和宽度、卷积核的数目等这几个超参数。我们所有的模型训练都将使用 Adam 优化器，因为它提供了梯度归一化和动量的方法，降低了像学习率这样的超参数对模型训练结果的影响。每个卷积层和隐藏层都使用整流线性单元（ReLU）作为激活函数，并使用  $dropout = 0.5$  来降低模型的过拟合，而预测时，我们使所有的单元处于激活状态。




图 1 本章所用 CNN 网络框架

### 0.2.1 模型的偏差与方差

偏差衡量机器学习算法对于输入样本的期望输出与真实值的偏离程度，本质上表征了机器学习算法本身的拟合能力。方差表示算法性能随训练集的变化而产生的波动，本质上表征了数据扰动所以对算法性能的影响。噪声则表示当前任务下，我们的训练数据与数据的真实值之间的差距，即任何学习算法所能达到的期望泛化误差的 F 下界，衡量了学习任务本身的难度。

我们假设调制识别的训练样本集为  $X$ ， $Y$  为训练样本的真实类别。对于训练集中的每一个样本  $x_i \in X$ ，假设其真实类别为  $\hat{y}_i$ ， $y_i$  为在训练集中的类别。在训练集  $X$  上学得模型  $\phi(\dots)$ ， $\phi(x_i; X)$  为输入样本为  $x_i$  时的输出，即预测类别：

$$y_i = \phi(x_i), x_i \in X \quad (0-2)$$

我们假设网络预测的期望为：

$$\bar{\phi}(x) = E_X [\phi(x; X)] \quad (0-3)$$

如果我们使用相同数目的不同训练样本集  $\hat{X}$  进行训练，那么我们有方差：

$$\delta_{\hat{X}}^2(x) = E_{\hat{X}} [(\phi(x, \hat{X}) - \bar{\phi}(x))^2] \quad (0-4)$$

此时，模型的噪声为  $\epsilon^2 = E_{\hat{X}} [(\hat{y} - y)^2]$ ，表示训练数据与真实数据的误差情况。模型的期望输出与真实标记的差别为偏差，即：

$$bias^2(x) = (\bar{\phi}(x) - \hat{y})^2 \quad (0-5)$$

我们假设噪声期望为 0，即  $E_{\hat{X}} [\hat{y} - y] = 0$ ，由 **■** 我们有泛化误差为偏差、方差与噪声之和：

$$E(\phi; X) = bias^2(x) + \delta_{\hat{X}}^2(x) + \epsilon^2 \quad (0-6)$$

为了简化模型的分析，我们假设所有的训练样本都是无偏的，即对于任意训练样本  $(x_i, y_i) \in X$ ，我们有  $\hat{y}_i \equiv y_i$ 。此时我们有泛化误差  $E(\phi; X)$ ：

$$E(\phi; X) = \text{bias}^2(x) + \delta_X^2(x) \quad (0-7)$$

因此，我们可以从降低偏差和方差的角度出发，来提升模型的性能。

### 0.2.2 过拟合与欠拟合

在训练机器学习模型时，我们以降低训练误差为目标，获得模型的参数。然而，我们不仅希望学习算法在训练集上表现良好，更希望其在非训练的数据集上同样具备良好的性能。泛化正是衡量机器学习算法在未知数据上表现能力良好的一种定性标准。泛化误差可以定义为模型对于新输入未知样本的误差期望。欠拟合是指模型不能在训练集上获得足够低的误差，而过拟合是指测试误差大于训练误差。

模型的容量是指模型的拟合能力。容量较低的模型其拟合能力较弱，很难反映训练集的数据分布。容量高的模型，由于其拟合能力过强，可能会将噪声数据也学习到模型中，从而发生过拟合。我们可以通过调整模型的容量，控制模型是否倾向于过拟合或者欠拟合。

通过小节0.2.1中的结果可知，模型的泛化性能是由学习算法本身的拟合能力、数据的充分性以及学习任务本身的难度共同决定的。

对于给定的学习任务  $T$ ，为了取得较好的泛化性能，我们需要使模型具备较小的偏差，即模型可以充分拟合训练数据，并且还要使模型的方差处于较小值，即使得数据扰动对模型产生的影响尽量小。

然而，实际中偏差与方差却具备相反的倾向性。在我们对算法进行训练时，如果训练不足，则机器学习模型的拟合能力不够强，训练数据的扰动不足以使模型产生显著变化，此时偏差主导了泛化误差；而随着训练程度的加深，模型的拟合能力逐渐增强，训练数据产生的扰动逐渐能被模型所学习，此时方差逐渐主导了泛化误差；在训练程度达到临界条件以后，如验证误差超过了训练误差一定阈值，模型的拟合能力已经非常强，训练数据发生的轻微扰动都会导致模型发生显著的变化，此时，模型可能学习到训练数据某些样本自身的、非全局性的特性，这就会产生模型的过拟合。

## 0.3 网络超参数对调制识别的影响

网络的超参数，如学习速率，每层卷积核的数量，卷积核的大小以及卷积层的数目等，会影响网络规模，特征提取的数目等，如果不具备一定的领域先验知识很难优化。

在本节中，我们将研究网络卷积核以及卷积层等相关超参数对分类性能的影响，这可以为我们后续的研究提供一定的网络整体架构的参考，节省了后续研究的时间成本，并有助于进一步探究新的网络底层架构，以提升调制识别的性能。

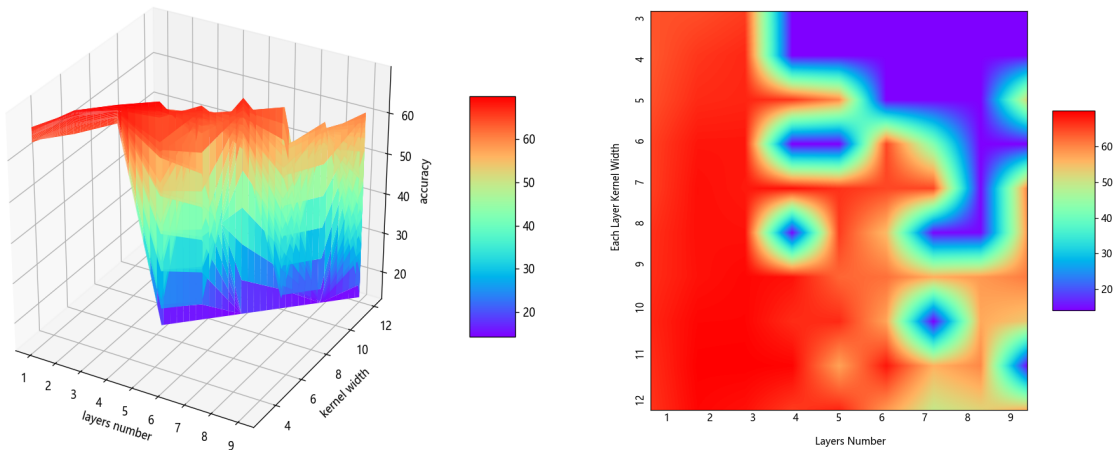
### 0.3.1 网络层数对调制识别的影响

在我们的调制识别场景中应用的是宽度较小的卷积核，由于小卷积核无法获取全局特征，所以我们通过增加网络层数，多层卷积核的局部感知野逐渐叠加后，较深层的卷积核的局部感知野也会逐渐扩大，进而学得全局特征。因此，卷积层的深度，在一定程度上决定了网络的拟合能力。

在本小节我们将探索网络层数对调制识别的影响。由于我们仅仅是探索卷积层深度对分类性能的影响，而且网络的训练本身是一个非常耗时的过程。因此，为了降低时间成本并简化分析提供一个定性的结果，我们在本小节中的仿真所有卷积核数目都为 32，并将卷积核的大小从  $1 \times 3$  到  $1 \times 12$  变化。

网络层次深度对训练数据遍历次数的要求差别很大，为了解决这个问题，我们将所有的网络 *epoch* 设置为一个较大值（本文中 *epoch* = 500），以满足那些对于复杂网络对于较高次数 *epoch* 训练的需求。同时，我们使用了预停止策略，假设训练过程中，训练损失在  $N_{pre\_stop}$ （本文中我们设置为  $N_{pre\_stop} = 10$ ）个 *epoch* 内不降低，即在这段训练时间范围内，模型不能得到很好的优化，此时我们则会停止训练。这样便可以在尽量保证准确率的同时提高训练效率。

根据我们的预设条件，系统的仿真结果如图2所示。



(a) 3D 展示  
(b) 热力图展示  
图 2 不同卷积核宽度下，卷积层数目对分类准确率的影响

通过图2我们可以发现，分类性能具有一个相对整体性的趋势：当卷积层大于 3 时，分类准确率几乎成下降趋势。通过图2a我们可以发现，系统性能在卷积层为 3，卷

积核的宽度为 6 以上时，系统性能能够达到一个较高的水准；同时我们可以发现卷积核宽度较大时，卷积核层数在大于 3 时分类准确率几乎呈一个断崖式下跌。

在图2b中我们可以清楚地发现，整幅图像在卷积层数目较大、卷积核数目较小时，系统的性能较差。卷积层数目小于 4 时，系统性能随卷积核宽度变化不大，增大卷积核宽度并不能很大程度上提升系统分类性能；卷积层较大时，增加卷积层的宽度反而会降低系统性能。

接下来，我们以卷积层数目作为变量，观察不同卷积核宽度条件下的分类性能，结果如图3。




图 3 分类准确率随卷积层数目和卷积核宽度的变化

从图4可以发现，整体而言，不同卷积核宽度的平均分类准确率，随着卷积层数目增加，首先先轻微地上升，然后出现较大幅度的下降。

增加卷积层的深度，在卷积层数目  $N_{layers} \leq 3$  时，可以微小地改善分类性能。当卷积层深度  $N_{layers} \geq 4$  时，改变卷积层的数量在分类准确率几乎都呈下降趋势；但是，不同卷积核宽度的网络性能下降程度不同，卷积核宽度较大的网络越，随着卷积层深度的增大性能下降程度较低。在卷积层深度  $N_{layers} \leq 3$  时，我们发现分类性能几乎随着卷积核宽度的增加而增加，直到卷积核宽度达到 11 时，达到分类性能的上限；同时，我们发现分类性能在此时随着卷积层数增加而增加。

在卷积层数较低时，分类性能有所增加，这可能是因为模型的拟合能力不足以完全表征信号的特性。在卷积层数  $N_{layers} \geq 4$  时，网络性能大幅下降；因为卷积核宽度较大时，分类性能仍然处于一个较高的水准，而且分类性能会随着卷积层数目的增加

而发生剧烈的突变，所以我们可以确定此时导致分类性能下降的主要原因是网络的训练难度增加；其次，网络性能在卷积层数目为 3 时达到了性能的最高点，之后性能一直呈下降趋势，我们认为这是网络发生过拟合的一个节点。这表明对于我们的数据而言，可能是由于调制数据通常只改变正弦曲线的幅度，频率或相位，因此对于调制方式而言数据的复杂度并不高，没有必要学习更高层次的深度特征。

### 0.3.2 卷积核数目对调制识别的影响

CNN 是通过增加网络的深度来增强拟合能力的，而网络对于数据特征的提取，主要是通过不同的卷积核进行参数学习得到的，卷积核的数目在一定程度上表征了网络所能学习特征的数目，即网络对数据理解的维度高低。

上一小节我们探究的是卷积层数目对调制识别的影响，本节我们将对网络结构进行更细化的研究，探索卷积核数目对调制识别的影响。

在第三章中，我们发现第一层卷积核为  $1 \times 7$ ，第二层卷积核为  $2 \times 6$  时，分类器具备较好的性能。因此，在本小节中，我们所有的仿真都基于这样的卷积核结构进行，变化的仅仅是卷积核的数目。由于我们训练神经网络时间成本较高，很难对每一个卷积核数目参数进行遍历，所以我们选择一些有代表性的参数进行试验，主要目的是定性的分析卷积核数目的变化对于分类性能的影响。我们定义卷积核数目集合  $\kappa = \{16, 32, 48, 64, 96, 128, 196, 256\}$ ，第一个卷积层与第二个卷积层的卷积核数目，分别从集合  $\kappa$  中按照卷积核数目由小到大选取，卷积核变化范围为 16 256。这样两个卷积层的核数目组合共有  $|\kappa|^2 = 64$  种，即网络训练时总的遍历次数为  $|\kappa|^2$  次，复杂度为  $O(n^2)$ 。同时使用自适应学习速率的 *Adam* 优化器进行训练，同样设置较大的 *epoch* 并应用预停止策略，来探索卷积核数目对分类性能的影响。

通过对不同卷积核数目组合的网络进行训练，我们最终得到分类器性能随卷积核数目变化的情况，图4显示了两个卷积层中卷积核数量从 16 增加到 256 时，样本分类准确率的变化情况。

通过图4，我们可以发现，在第一层卷积核数目为 16，即第一层卷积核数目较小时，网络的性能几乎随着第二层卷积核数目的增大而减小。而随着第一层卷积核增大，改变第二层卷积核数目，系统分类准确率变化很小，只有轻微的波动。由于我们使用的是较小的卷积核，因此单卷积层的卷积核的局部感知野有限，我们通过增加卷积层的数目来增大卷积核的局部感知野。当我们第一个卷积层的卷积核数目较小时，我们所学得的特征图的数目也相对较少，而此时增大第二个卷积层的卷积核数目，由于第二层卷积核本身所能感知的信息较多，我们第一个卷积层提取的信息量有限，因此第二层很难得到有效训练。所以，我们认为之所以这种情况下网络性能下降较为明显，是因为网络本身训练难度增加所致。




图 4 分类准确率随卷积核数目的变化情况

图5中，我们以第一个卷积层中卷积核数目为横轴，展示第一层和第二层卷积核数目变化对分类性能的影响。




图 5 第一卷积层中卷积核数目对分类准确率的影响

从图5a我们可知第一卷积层中卷积核数目  $N_{kernel}^{(1)} \leq 32$  时，系统性能会随着第二层中卷积核的数目变化而发生较大的波动；而当  $N_{kernel}^{(1)} \geq 48$  时，第二个卷积层中卷积核数目变化对系统性能影响较小。这可能是由于在第一层卷积核数目较小时，偏差主导了我们模型的泛化性能。

从图5b我们可以发现，第一卷积层中卷积核数目  $N_{kernel}^{(1)} \leq 32$  时，第二层卷积核



数目的变化与性能没有明确的相关关系，但是，整体而言，第二层的卷积核数目在  $N_{kernel}^{(2)} \leq 48$  时能取得较好的性能。而在第一个卷积层数目  $N_{kernel}^{(1)} \geq 48$  时，系统性能波动较大，此时可能是模型训练时的鞍点等因素所致。当我们以第一层卷积核数目作为自变量，第二层所有数目卷积核分类准确率的均值作为因变量时，即图5b中红色的粗线，我们发现其整体上准确率呈先上升后下降的趋势，系统性能在  $N_{kernel}^{(1)} = 64, N_{kernel}^{(2)} = 64$  时取得最优。




图 6 第二卷积层中卷积核数目对分类准确率的影响

从图6a中我们可以发现，分类性能整体随着第二卷积层数目的增加而下降。而且，当第一卷积层中卷积核数目为 16 时，性能下降的最为明显。图6b中我们可以更清楚的看到，当第一层卷积核数目较小时，系统性能随着第二卷积层中卷积核数目的增加而下降得很明显，而且波动幅度较大；从平均准确率而言，我们也可以看到图中粗的红色实线也是呈下降趋势，即系统整体性能几乎是随着第二卷积层数目的增加而下降的。

由于网络本身的深度较小，当卷积核数目很小时，受限于卷积核数目的限制，特征提取的数目也相应的较少，很难较完整地反映数据本身的特征，分类准确率的上限会出于一个较低值。当卷积核数目增加，相当于我们的特征数目也在相应的增加，这样，网络本身的拟合能力增强，卷积核所提取的卷积特征能更好地反映数据的内在特征，因此，分类性能的上界相应提高，可以获得较好的分类结果。

当卷积核的数目增大到一定的程度，网络的拟合能力过强，不仅能够拟合出数据本身的性质，同时一些异常点也进行了拟合，这就造成了过拟合；同时，由于我们的数据量有限，也很难将网络参数训练到一个较优的水平。因此，我们的分类性能可能会随着卷积核数目的增加而降低。

由于不同卷积层中的卷积核局部感知野不同，越深度的卷积核相对而言观察的



信息范围更广，因此，更深层次的卷积层中卷积核数目应该相对较少；如果较深层的卷积核数目大于较浅层中卷积核数目，模型就容易发生过拟合现象。

### 0.3.3 卷积核大小对调制识别的影响

在 CNN 中，特征提取的过程从底层卷积核到高层卷积核，层层接收局部的输入，最后不断聚合。对于卷积核而言，卷积核的高度  $height$  和宽度  $width$  决定了卷积核感知野的范围。在本小节我们将探究卷积核的高度和宽度对调制识别性能的影响。

根据第三章我们采用的卷积神经网络结构，我们将第一个卷积层的卷积核数目固定在 64，将第二个卷积层的卷积核数目固定在 32，因为这种情况下网络具有较好的分类性能。我们假设卷积核高度  $H^{(1)}$  和  $H^{(2)}$  在 1 与 2 之间变化，卷积核的宽度  $W^{(1)}$  和  $W^{(2)}$  在 3 到 12 之间变化。则总的训练迭代次数为  $10 \times 10 \times 2 \times 2 = 400$ 。我们同样适用 *Adam* 优化器，并使用了预停止策略，最后分类结果如图7所示。




图 7 卷积核大小对分类性能的影响

每个卷积层的卷积核尺寸变化的结果表明：1. 对卷积核的宽度而言，整体而言较小的卷积核不如较大的卷积核，但是当卷积的宽度增大到 7 之后，分类性能变化很小；2. 对卷积核的高度而言，当第一层卷积核的高度为 1，第二层卷积核的高度为 2 时，我们可以获得相对最优分类性能。

通过图3我们可以发现卷积核宽度为 6 – 9 时网络的分类性能可以达到一个较高的水准。这些数目的卷积核宽度相互之间有一定的差异，但是考虑到网络能达到的只是一个局部极小值，而非全局极小值，我们很难定量的确定到底怎样的卷积核大小是一个最优值。但是可以确定的是，由于我们的信号样本是 128 个采样点，而每个样本包含 8 到 16 个符号，也就是每个符号占用为 16 或者 8 个采样点。因此，我们的卷积核宽度为 8 时，每次卷积操作相当于对 1 个符号或 1/2 个符号进行运算，此时，分类器的性能很有可能达到一个相对较优的水平。




图 8 不同卷积核宽度下，卷积层数目对分类准确率的影响

对于卷积层的高度而言，由于我们的样本是一个  $2 \times 128$  的时间序列，我们可以

看成是由两行 128 维的向量组成。其中，第一行表示信号的实部，第二行为信号的虚部。这样，我们在利用卷积核对信号进行卷积特征提取时，如果卷积核的宽度为 1，相当于是对信号的实部进行采样值的卷积运算；如果卷积核的宽度为 2 表示我们不仅对信号进行实部的运算，同时考虑到了信号的虚部，这样进行卷积时，可能同时会包含信号的能量信息。当然，这些只是我们从理论层面的一些分析，具体卷积核维度变化相应于我们信号的哪一些特征，有待后续的进一步研究。但是，可以确定的是，卷积的操作提取的不仅仅是某些确定的特征，而很有可能是某些信号特性本身的体现，而且这些卷积特征随着参数的初始化、卷积核的维度变化所表征的含义也是完全不同的。

## 0.4 本章小结

深度神经网络在无线电领域的性能似乎不受网络深度的限制。虽然我们的实验将调制识别作为基准任务，但我们期望其他无线机器学习任务能够使用类似的网络架构。无线电任务深度学习的进一步发展可能来自改进的训练方法和网络架构，这些架构可以学习转换射频数据以消除无线信道的影响，而这些神经网络架构并非为此设计的。目前正在探索的一个例子是使用空间变换来均衡和同步输入波形 [14]。

这些实验还着重于名义上带宽归一化的数据集，这是对从真实无线电传输中捕获的信号的不良假设。将来在实际应用中使用的网络需要学习对信号进行重新采样以获得带宽规格化，或者学习许多带宽的特性。可重新采样，同步和消除非线性信道失真的网络都是该领域未来令人兴奋的工作。我们相信，随着无线电环境变得越来越复杂，将调制，多调制协议的不同时间行为和多个无线电发射机组合在一个频带内进行互操作，这些深层网络中的层次结构的许多概念将越来越重要，使我们的网络可以有效地应对复杂性，正如在复杂的多物体场景中的视觉域中所显示的一样。