

DOI:10.13364/j.issn.1672-6510.20160407

一种基于深度学习模型的数据融合处理算法

马永军, 薛永浩, 刘 洋, 李亚军
(天津科技大学计算机科学与信息工程学院, 天津 300457)

摘 要: 针对无线传感器网络传统数据融合算法效率较低、处理高维数据困难问题, 提出一种基于深度学习模型的卷积神经网络结构实现数据融合的算法 CNNMDA. 算法首先在汇聚节点对构建的特征提取模型 CNNM 进行训练, 然后各终端节点通过 CNNM 提取原始数据特征, 最后向汇聚节点发送融合后的数据, 从而减少数据传输量, 延长网络寿命. 仿真实验表明, CNNMDA 与同类融合算法相比, 在同样数据量的情况下能够大幅降低网络能耗, 并有效提升了数据融合效率与准确度.

关键词: 数据融合; 深度学习; 无线传感器网络; 卷积神经网络

中图分类号: TP393; TP183 **文献标志码:** A **文章编号:** 1672-6510(2017)04-0071-04

Data Aggregation Algorithm Based on the Model of Deep Learning

MA Yongjun, XUE Yonghao, LIU Yang, LI Yajun

(College of Computer Science and Information Engineering, Tianjin University of Science & Technology,
Tianjin 300457, China)

Abstract: Traditional methods of data fusion in wireless sensor networks (WSNs) are inefficient and not ideal for processing high-dimensional data. Therefore, a data aggregation algorithm CNNMDA (convolutional neural networks model data aggregation) was proposed, which combined convolutional neural networks (CNN) and WSNs clustering routing protocol. A feature extraction model (CNNM) is designed by using CNNMDA firstly and then trained in Sink node. After that the cluster nodes use CNNM to extract data features, which are sent to the Sink node by cluster heads, thereby reducing the quantity of data transmission and extend the network lifetime. Simulation results show that compared with existing similar algorithms, the energy consumption of CNNMDA decreases obviously and the accuracy of the data fusion can be effectively improved.

Key words: data aggregation; deep learning; wireless sensor networks; convolutional neural network

随着物联网技术的快速发展, 无线传感器网络 (wireless sensor networks, WSNs) 作为物联网感知层的核心组成部分, 在各类环境监测领域得到了广泛应用^[1]. 而实际中各传感器节点多采用电池供电, 导致网络内资源十分受限; 大量节点由于地理位置分布不均, 使得数据存在过多冗余信息^[2], 从而增加了能量消耗与传输延时; 此外, 由于物联网应用环境普遍存在较多干扰, 会直接减弱数据通信传输能力, 并降低数据采集精度, 影响了物联网系统整体性能.

为解决以上问题, 针对 WSNs 的数据融合技术

应运而生, 其主要思想是将多个不同源节点传来的数据进行融合, 以消除冗余, 减少数据传输量, 从而提高网络性能、延长网络寿命并降低能耗.

传统的融合算法多是基于 BP 神经网络^[3-7]、SOFM^[8]等浅层网络模型, 这些模型易出现过拟合、模型训练陷入局部极小、收敛速度过慢等问题, 导致算法效率降低、特征提取分类能力变弱, 且无法有效地处理高维数据. 针对上述缺陷, 深层模型的应用成为数据融合发展的一个新方向. 2006 年 Hinton 等^[9]提出“深度学习”的概念; 此后, 卷积神经网络

收稿日期: 2016-12-14; 修回日期: 2017-02-18

基金项目: 天津市教委重大项目 (2014ZD22)

作者简介: 马永军 (1970—), 男, 山东日照人, 教授, yjma@tust.edu.cn

数字出版日期: 2017-04-20; 数字出版网址: <http://kns.cnki.net/kcms/detail/12.1355.N.20170420.1445.006.html>

(convolutional neural networks, CNN)^[10]、栈式自编码器(SAE)等模型被广泛应用. 目前深度学习在数据融合领域已有研究, 文献[11]和文献[12]提出使用深度学习中的 SAE 模型对 WSNs 数据进行特征融合, 显著提高了融合的正确率; 文献[13]结合深层模型与稀疏滤波算法, 设计了 BSSFM 模型提取数据特征, 提升了融合的效率并降低了能耗. 但使用 SAE 等模型在训练过程都会产生大量权值参数, 增加了模型训练的难度.

本文将深度学习中的卷积神经网络结构引入到 WSNs 数据融合应用中, 提出以 CNNM 作为特征提取模型的数据融合算法 CNNMDA (convolutional neural networks model data aggregation). 算法利用 CNN 权值共享的特性减少了训练参数, 使得模型易于训练, 并且能更好地处理高维数据.

1 深度学习算法模型

深度学习属于机器学习的一个分支, 近年来已在多个领域取得突破性进展. 其中卷积神经网络是深度学习中最重要的结构模型之一.

1.1 CNN 概念与网络结构

卷积神经网络(CNN)是一种多层人工神经网络^[10], 其基本网络结构包括卷积层与池化层, 其中卷积(convolution)层对输入层使用多个卷积核进行特征提取, 得到多个特征图; 池化(pooling)层是通过池化函数降低特征图的维度, 并在保持准确率的情况下尽量控制过拟合, 同时减少参数数量.

卷积神经网络典型结构如图 1 所示, 其中 Input 为输入层, 经过卷积操作后得到卷积层 Layer1, 对 Layer1 进行池化操作得到池化层 Layer2, 再经过卷积和池化操作得到 Layer3 卷积层和 Layer4 池化层, 最终由全连接层进行分类输出.




图1 卷积神经网络结构图

Fig. 1 Structure of convolutional neural network

1.2 卷积池化过程原理

卷积阶段首先通过多个卷积核对输入数据进行卷积操作, 然后形成由多个特征图组成的卷积层. 图

2 为卷积过程, 假设输入数据是 $i_1 \times i_2$ 的二维数组, 使用 n 个 $k_1 \times k_2$ 的卷积核对输入特征图进行卷积, 然后输出为 n 个二维数组组成的特征图.




图2 卷积阶段原理图

Fig. 2 Workflow of convolution phase

$$y_j = f\left(\sum_i w_{ij} * x_i + b_j\right) \quad (1)$$

式中: w_{ij} 为每个卷积核的权重; y_j 为输出的第 j 个特征图; x_i 为输入的第 i 个特征图; b_j 为可训练的偏置; f 为激励函数; 常用的 ReLU 激励函数表达式为

$$f(x) = \max(0, x) \quad (2)$$

池化阶段可对卷积后的特征图降维, 并有效防止过拟合, 同时减少训练参数, 从而降低模型训练时间. 目前常采用的池化方法有最大池化(max pooling), 其过程原理如图 3 所示. 在一个 4×4 的特征图中, 使用一个 2×2 的滤波器, 以 2 为步长对特征图进行遍历, 在每个滤波器遍历的区域内取最大值来代替该区域, 遍历后得到图中所示新的 2×2 特征图.




图3 池化阶段原理图

Fig. 3 Workflow of pooling phase

1.3 Logistic 回归

Logistic 回归是一种常用且高效的分类器, 具有无需事先假设数据分布和模型数学性质良好等诸多优点. 卷积神经网络的最后一层一般为分类层, CNNMDA 采用 Logistic 回归作为 CNN 的分类层. Logistic 回归模型的假设函数为

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}} \quad (3)$$

该函数也称为对率函数, 是任意阶可导的凸函数, $h_{\theta}(x)$ 代表对于样本 x 某事件发生的概率, θ 为可训练的参数.

在二分类问题中对于给定的样本 x , 属于 0 类的

概率为

$$P(y=0|x;\theta)=1-h_{\theta}(x) \quad (4)$$

属于 1 类的概率为

$$P(y=1|x;\theta)=h_{\theta}(x) \quad (5)$$

对于多分类问题, 可使用 one-vs-all 方法转化为二分类问题.

2 CNNMDA 数据融合算法

CNNMDA 算法基于深度学习模型, 所使用的 CNN 网络结构共含有 3 个卷积层、1 个池化层和 2 个全连接层. 在利用特征提取模型 CNNM 对节点数据进行融合之前, 需要完成该模型的训练. 传统训练方法主要为反向传播算法, 而 CNNM 模型由于卷积层和池化层的存在, 需要对反向传播算法进行相应的修改.

CNNM 训练的损失函数为

$$J(\theta)=-\frac{1}{m}\left[\sum_{i=1}^m y^{(i)} \ln h_{\theta}\left(x^{(i)}\right)+\left(1-y^{(i)}\right) \ln \left(1-h_{\theta}\left(x^{(i)}\right)\right)\right]$$

训练的目标通过式 (6) 给出.

$$\theta_i=\theta_i-\alpha \frac{\partial}{\partial \theta} J(\theta) \quad (6)$$

不断迭代更新参数以最小化损失函数 $J(\theta)$, 其中 θ 为可训练的参数 (包括卷积核的权重和偏置), α 为学习率.

为求出偏导数 $\frac{\partial}{\partial \theta} J(\theta)$, 对于卷积层有

$$\delta_j^l=\beta_j^{l+1}\left(f'\left(u_j^l\right) \cdot \text{up}\left(\delta_j^{l+1}\right)\right) \quad (7)$$

式中: δ_j^l 为第 l 层第 j 个特征图的灵敏度; β_j^{l+1} 为第 $l+1$ 层第 j 个特征图的参数. 将 δ_j^l 代入式 (8) 和式 (9) 可以得到卷积核权重 w 和偏置 b 的导数.

$$\frac{\partial J}{\partial w_{ij}}=\sum_{u,v}\left(\delta_j^l\right)_{uv}\left(p_i^{l-1}\right)_{uv} \quad (8)$$

$$\frac{\partial J}{\partial b_j}=\sum_{u,v}\left(\delta_j^l\right)_{uv} \quad (9)$$

式中 $\left(p_i^{l-1}\right)_{uv}$ 为第 $l-1$ 层特征图与第 l 层卷积核进行卷积操作的结果. 此时, 即可将式 (8) 和式 (9) 代入式 (6), 完成一次卷积层的参数更新.

对于池化层有

$$z_j^l=f\left(\beta_j^l \text{down}\left(z_j^{l-1}\right)+b_j^l\right) \quad (10)$$

$$\delta_i^l=\sum_{j=1}^M \beta_i^{l+1} * k_{ij} \quad (11)$$

式中: z_j^l 代表第 l 层的第 j 个特征图; down 表示执行一次池化操作. 通过式 (10) 和式 (11) 求得卷积核的权重与偏置的导数, 如式 (12) 和式 (13) 所示, 然后将其结果代入式 (6) 完成一次池化层的参数更新.

$$\frac{\partial J}{\partial w_{ij}^l}=z_j^l * \delta_j^{l+1} \quad (12)$$

$$\frac{\partial J}{\partial b_j}=\sum_{u,v}\left(\delta_j^l\right)_{uv} \quad (13)$$

对于卷积神经网络最后的全连接层, 仍采用传统的反向传播算法进行训练. 利用式 (6) 一式 (13) 对反向传播算法进行改进, 同时结合前向传播过程完成 CNNM 模型的训练, 最后得到模型参数, 即可按算法实现 CNNMDA. 具体算法步骤如下:

(1) Sink 节点根据需要处理的数据类型, 从相应数据库中提取含有标签信息的数据;

(2) 将训练数据输入至构建的 CNNM 模型, 开始训练 CNNM, 然后 Sink 节点将训练好的参数通过簇头发送至各终端节点;

(3) 各终端节点使用预训练的 CNNM 模型, 对采集的传感器数据进行多层卷积特征提取与池化, 然后将融合得到的特征数据发送至相应的簇头节点, 其中卷积与池化的过程就是数据融合的过程;

(4) 簇头节点利用 Logistic 回归分类器对步骤 (3) 产生的融合数据进行分类, 得到分类结果, 并向 Sink 节点发送融合数据;

(5) 网络完成一轮数据采集融合与传输过程, Sink 节点重新分簇和选取簇头节点, 然后跳转到步骤 (3).

通过本算法对簇节点传入的数据进行数据融合可减少其传出数据量的大小, 从而大大降低能耗, 提升网络性能.

3 仿真实验

采用 Matlab 平台对数据融合算法进行仿真分析, 以设施农业监测系统作为应用场景, 按照第 2 节的算法完成 CNNMDA 算法的仿真测试. 为突出 CNNM 深层模型数据融合的性能, 采用基于浅层网络模型的代表算法 BPMDA^[7]和 SOFMDA^[8]进行对比分析.

仿真参数见表 1, 其中节点数量和网络范围是指将 100 个传感器节点随机分布在 100 m × 100 m 范围的感知区域内^[7]. 为对比各数据融合算法的效率, 采

用未优化的 LEACH^[14]协议,并按照第一类无线通信能耗模型^[15]统计节点发送、接收和融合数据的能量消耗。

表1 仿真参数

Tab. 1 Simulation parameters

参数	取值	参数	取值
网络范围	100 m × 100 m	数据包长度	2 000 bit
节点数量	100 个	分簇消息长度	100 bit
Sink 节点坐标	(50, 50)	包头长度	100 bit
节点初始能量	0.5 J	最大仿真轮数	2 000
卷积核大小	3 × 3	卷积步长	1

各算法的特征提取分类错误率见表 2, 其中 n 、 d 、 c 分别表示 BP 网络模型的网络层数、输入数据的维数以及数据分类数。从表 2 可以看出: 对于低维少类别数据, CNNMDA 算法的特征提取分类错误率与 BPNDA 和 SOFMDA 基本持平; 随着输入数据维数的升高, 浅层模型 BP、SOFM 的参数数量急剧增加, 开始出现性能的下滑, 导致错误率明显升高; 相比之下, 基于深度模型的 CNNMDA 错误率则始终保持在较低水平。

表2 不同算法的特征提取分类错误率

Tab. 2 Inaccuracy of feature extraction and classification of different algorithm

算法	错误率/%			
	$d=200,$ $c=4$	$d=600,$ $c=6$	$d=900,$ $c=12$	$d=2\,500,$ $c=12$
BPNDA ($n=4$)	7.3	15.6	18.5	27.0
BPNDA ($n=5$)	7.0	13.1	15.1	24.8
SOFMDA	6.7	12.7	14.9	23.5
CNNMDA	6.5	8.3	9.2	11.6

各算法特征提取分类过程的平均耗时见表 3。分析可知: CNNMDA 相比 BPNDA 和 SOFMDA, 具有较高的执行效率, 能够实现更快速的数据融合, 并且基于 CNN 强大的降维能力, 随着输入数据维数升高, CNNMDA 相比另外两种算法的特征提取耗时大大缩短, 表现出处理高维数据时的优势。


表3 不同算法的特征提取分类平均耗时

Tab. 3 Average time of feature extraction and classification of different algorithm

算法	耗时/ms			
	$d=200,$ $c=4$	$d=600,$ $c=6$	$d=900,$ $c=12$	$d=2\,500,$ $c=12$
BPNDA ($n=4$)	4.60	7.49	9.01	38.26
BPNDA ($n=5$)	5.38	7.93	9.47	40.85
SOFMDA	4.16	6.82	8.33	32.71
CNNMDA	3.07	3.15	3.60	9.39

各算法在 $d=2\,500$, $c=12$ 时的节点能耗对比如图 4 所示(其他输入得到的结果类似)。由图 4 可知:

随着仿真轮数的增加, 网络总能量不断消耗, 而使用 CNNMDA 算法的节点能量消耗速度均低于 BPNDA ($n=5$) 和 SOFMDA 算法, 同时这 3 种融合算法产生的能耗皆远低于未进行数据处理的 LEACH, 这表明通过利用数据融合算法可使网络中需要传输的数据包数量大大降低, 进而减少传输能耗, 延长了网络寿命。此外, 随着输入数据维数升高, BPNDA 与 SOFMDA 的处理能力大幅下降, 而 CNNMDA 的融合效率则一直保持相对较高的水平; 相比之下, 使用 CNNMDA 的网络节点能耗平均可以降低 7.3%, 这表明 CNNMDA 具有较高的数据融合效率。

图4 不同算法的网络节点能耗 ($d=2\,500$, $c=12$)Fig. 4 Energy consumption of node of different algorithm ($d=2\,500$, $c=12$)

4 结 语

本文将深度学习模型应用在 WSNs 数据融合领域中, 提出了以卷积神经网络模型为核心的数据融合算法 CNNMDA。仿真实验表明, 相比传统基于 BP、SOFM 等浅层网络模型的融合算法, CNNMDA 以深层模型中的 CNN 结构为特征提取模型, 可有效地提高数据采集精度, 降低错误率, 同时可大幅减少网络通信数据量与节点能耗, 延长网络生命周期, 取得较好的融合效果。

深度学习模型在数据融合领域的应用前景十分广阔, 如何更好地简化模型参数、提高算法执行效率仍需要更深入研究。

参考文献:

- [1] Pinto A R, Montez C, Araújo G, et al. An approach to implement data fusion techniques in wireless sensor networks using genetic machine learning algorithms[J]. Information Fusion, 2014, 15(1): 90-101.

(下转第 78 页)

5 结 语

应急物流配送公路网络的最短路径问题一直是研究的热点. 本文通过分析应急物流配送公路网络特征, 根据实际物流配送过程中会不断有信息更新的情况, 构建了动态最短路径模型. 结合 Dijkstra 算法解决路径优化问题的特点, 分析了解决思路, 并通过北京地区某公路网络算例, 验证了构建的应急物流配送公路网络最短路径模型的有效性.

参考文献:

- [1] 可可. 应急物流配送路径优化研究[J]. 物流工程与管理, 2011, 33(7): 63–65.
- [2] 赵彤, 范厚明, 王桂林, 等. 带时间窗的应急救助物资配送车辆路径优化路径模型[J]. 物流技术, 2010(20): 63–65, 68.
- [3] Zhu A D, Ma H, Xiao X K, et al. Shortest path and distance queries on road networks: Towards bridging theory and practice[C]//Proceedings of the 2013 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2013: 857–868.
- [4] Mahadeokar J, Saxena S. Faster algorithm to find anti-risk path between two nodes of an undirected graph[J]. Journal of Combinatorial Optimization, 2014, 27(4): 798–807.
- [5] 杨谊, 喻德旷. 道路突发中断情况下实时最短路径快速求解算法[J]. 计算机应用, 2016, 36(S1): 90–94.
- [6] 韦晓, 常相全. 动态需求条件下应急物流路径优化问题研究[J]. 系统工程, 2015(6): 25–26.
- [7] 王旭, 葛显龙, 代应. 基于两阶段求解算法的动态车辆调度问题研究[J]. 控制与决策, 2012, 27(2): 175–181.
- [8] 向冬梅, 陈树辉. 基于动态交通的最短时间路径规划方法研究[J]. 微计算机信息, 2012, 28(9): 317–319.
- [9] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527–1554.
- [10] Lecun Y L, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278–2324.
- [11] 邱立达, 刘天键, 傅平. 基于深度学习的无线传感器网络数据融合[J]. 计算机应用研究, 2016(1): 185–188.
- [12] 邱立达, 刘天键, 林南, 等. 基于深度学习模型的无线传感器网络数据融合算法[J]. 传感技术学报, 2014(12): 1704–1709.
- [13] 邱立达, 刘天键, 傅平. 基于稀疏滤波的无线传感器网络数据融合[J]. 电子测量与仪器学报, 2015(3): 352–357.
- [14] Heinzelman W R, Chandrakasan A, Balakrishnan H. Energy-efficient communication protocol for wireless microsensor networks[C]//Proceedings of the 33rd Annual Hawaii International Conference on System Sciences. Piscataway: IEEE, 2000: 1–10.
- [15] Heinzelman W B, Chandrakasan A P, Balakrishnan H. An application-specific protocol architecture for wireless microsensor networks[J]. IEEE Transactions on Wireless Communications, 2002, 1(4): 660–670.

责任编辑: 常涛

(上接第 74 页)

- [2] 吴昊, 刘金刚. 蚁群算法在传感器网络数据融合中的应用[J]. 计算机仿真, 2012, 29(11): 256–259.
- [3] 周观民, 李荣会. 基于神经网络的传感器网络数据融合技术研究[J]. 计算机仿真, 2011, 28(10): 118–120.
- [4] 边鹏飞, 何志琴, 唐杰. 无线传感器网络数据融合算法的改进与实现[J]. 自动化与仪表, 2016(6): 36–41.
- [5] 连方圆, 白静. 一种改进的基于神经网络的 WSN 数据融合算法[J]. 计算机测量与控制, 2014, 22(2): 476–479.
- [6] 樊雷松, 强彦, 赵涓涓, 等. 无线传感网中基于 BP 神经网络的数据融合方法[J]. 计算机工程与设计, 2014, 35(1): 62–66.
- [7] 孙凌逸, 黄先祥, 蔡伟, 等. 基于神经网络的无线传感器网络数据融合算法[J]. 传感技术学报, 2011, 24(01): 122–127.
- [8] 杨永健, 刘帅. 基于 SOFM 神经网络的无线传感器网络数据融合算法[J]. 传感技术学报, 2013(12): 1757–1763.
- [9] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527–1554.
- [10] Lecun Y L, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278–2324.
- [11] 邱立达, 刘天键, 傅平. 基于深度学习的无线传感器网络数据融合[J]. 计算机应用研究, 2016(1): 185–188.
- [12] 邱立达, 刘天键, 林南, 等. 基于深度学习模型的无线传感器网络数据融合算法[J]. 传感技术学报, 2014(12): 1704–1709.
- [13] 邱立达, 刘天键, 傅平. 基于稀疏滤波的无线传感器网络数据融合[J]. 电子测量与仪器学报, 2015(3): 352–357.
- [14] Heinzelman W R, Chandrakasan A, Balakrishnan H. Energy-efficient communication protocol for wireless microsensor networks[C]//Proceedings of the 33rd Annual Hawaii International Conference on System Sciences. Piscataway: IEEE, 2000: 1–10.
- [15] Heinzelman W B, Chandrakasan A P, Balakrishnan H. An application-specific protocol architecture for wireless microsensor networks[J]. IEEE Transactions on Wireless Communications, 2002, 1(4): 660–670.

责任编辑: 常涛